

基於 PPG 之瘻管功能異常分析

Analysis of Abnormal Fistula Function Based on PPG

Po-Kai Yang, Ming-Chao Wu, Wen-Fong Wang*



摘要

現今在台灣末期腎病的病患約 90% 會接受血液透析治療。當病患接受長期血液透析時必須建立長期血管通路(vascular access)方便上針。自體動靜脈瘻管(arteriovenous fistula, AVF)及人工動靜脈瘻管(arteriovenous graft, AVG)為病患接受血液透析時併發症較低的血管通路(vascular access)選項，但使用一段時間後，血管可能產生狹窄、血栓、或形成假性動脈瘤(pseudoaneurysm)，若血管完全阻塞會導致病患多餘的水分及毒素無法及時自體內排出，甚至造成生命危險。

2020KDOQI 血管通路照護指引指出，目前仍無足夠證據顯示常規用儀器監測血管通路狹窄對血管通路通暢度維持有幫助。目前有許多針對血管通路功能的感測器，然而這些感測器大多以監測(surveillance)血管狹窄程度作為目標，較少有文獻針對預測血管通路的通暢率及預後直接進行著墨。光電容積圖(photoplethysmography, PPG)以非侵入性方式獲得血管隨脈衝壓引起的體積變化，有較高的準確率去分類瘻管狀態。

因此，本研究將受試者分為「易阻塞病患」、「不易阻塞的病患」兩個群體，利用 ADInstruments PowerLab 醫學級研究用感測儀器採集且濾波之訊號數據 (PPG 值)，分析群體間之差異，監測透析瘻管健康程度。

關鍵字:血液透析、瘻管、光體積變化描記圖法、互相關運算、機器學習

ABSTRACT

In Taiwan, about 90% of end-stage renal disease(ESRD) patients received hemodialysis(HD) treatment. Arteriovenous fistula(AVF) and arteriovenous graft(AVG) are the preferred access for most patients receiving maintenance HD due to the lower complication rate. However, it is often complicated with thrombus formation, vascular access dysfunction, and failure in the long term. These complications prevent patients from receiving regular dialysis on schedule until an emergent thrombectomy is performed. Delay hemodialysis may cause excessive water accumulation or electrolyte imbalance, which becomes a life-threatening condition.

Currently, care of vascular access can be categorized into “surveillance” and “monitoring”. The 2020 update of the KDOQI guideline does not recommend using these surveillance methods as the sole indicator to do a vascular intervention. Many works on noninvasive sensors for evaluating AVF were published but mostly focused on the degree of stenosis. For direct predicting of patency of AVF, there’s still limited work on it. To acquire the hemodynamic status of a certain vessel, as a technique of optical measurement, photoplethysmography(PPG) is an appropriate option.

The study population is divided into two groups: “recurrent access dysfunction”, “good access patency”. We use ADInstruments PowerLab sensors to obtain PPG signal, and analyze differences between groups. This study aims to investigate whether the PPG signal can be a predictor for the patency of AV fistula.

Keywords:Hemodialysis 、Fistula 、Photoplethysmography 、Auto-/Cross-Correlation, Machine Learning.

第一章 介紹

1.1 研究背景

在台灣，目前末期腎病(End-stage renal disease, ESRD)的病患約 80000 人[1]，治療末期腎病最常用的方法為血液透析(Hemodialysis, HD)。現今在台灣末期腎病的病患約 90%會接受血液透析治療，當病患接受長期血液透析時必須建立長期血管通路(vascular access)方便安裝輸血針頭進行血液透析治療。一般來說，血管外科醫師會根據病患自身血管狀況作評估，決定血管通路的方式。

自體動靜脈瘻管(arteriovenous fistula, AVF)及人工動靜脈瘻管(arteriovenous graft, AVG)因為併發症少、感染率低，相較於其他血管通路(如：中心靜脈導管(central venous catheter))等方法，是較好且較常見的選項[3]。然而，不論自體動靜脈瘻管或人工動靜脈瘻管，都有其缺點。在早期階段，瘻管可能在手術後無法順利成熟，成為可用的血管通路。隨著時間推移，血管可能產生狹窄、血栓、或形成假性動脈瘤(pseudoaneurysm)等現象。在進行血液透析治療時，透析護理師需對病患之瘻管進行反覆穿刺上針，導致瘻管的血管內膜組織增生或血管壁重塑，進而形成血管狹窄。而血管狹窄容易導致瘻管通路流速下降，從而造成血栓或瘻管通路功能異常等現象[4]。若瘻管通路功能異常甚至完全阻塞時，病患將無法接受常規的血液透析治療，必須先接受緊急血栓移除手術(thrombectomy)將血管打通，才能繼續接受血液透析治療。有些病患可能因此導致多餘的水分及毒素無法及時自體內排出，甚至造成生命危險。

1.2 相關研究

目前有許多針對血管通路功能的感測器，然而這些感測器大多以監測(surveillance)血管狹窄程度[5]作為目標。但 2020KDOQI 血管通路照護指引指出，

目前仍無足夠證據顯示，使用常規儀器來監測血管通路的狹窄化，對血管通路通暢度之維持有幫助[6]。這其中的疑問包括：1. 偵測工具是否真的能可靠地偵測血管內狹窄 2. 目前對於何種程度的狹窄日後會造成血管通路阻塞仍無定論 3. 除了狹窄之外，還有其他原因可能造成血管通路阻塞。

由許多研究顯示，我們可以根據從雙手同樣的手指或是有瘻管之手臂等部位，擷取出心搏活動在動脈和微血管所引發之心搏脈衝訊號變化，例如：以光體積變化描記圖法(Photoplethysmography, PPG)所產生的光電訊號，以進行該類訊號的比對和分析。P.-Y. Chiang 等人透過自製的無線 PPG 感測器，採集瘻管隻手臂的 PPG 訊號，感測器計算參數經過神經網路訓練的結果與醫院的超音波多普勒血流儀器對比具有高度相關[7, 8]。另外，為了能夠有較高的準確率去分類出瘻管窄化等級之結果，J.-X. Wu 等人利用雙側手指 PPG 訊號的上升時間和振幅的差異，以便反映出狹窄程度[9]。Y.-C. Du 等人也利用雙側手指 PPG 訊號，計算洗腎前/後的上升斜率與下降斜率對瘻管窄化進行分類[10, 11]。上述這些研究都是針對瘻管窄化進行分析，但因瘻管窄化無法與血管通路阻塞的機率畫上等號，因此距離臨床直接應用仍有一段距離。

1.3 研究動機(問題)及解決方案

PPG 是通過 LED 光線照射皮膚下的微血管，並測量光吸收的變化量，是一種以非侵入性方式，獲得血管隨脈衝壓引起的體積變化。因此，本研究將受試者分為接受血液透析治療之瘻管通路是「易阻塞病患」和「不易阻塞的病患」等兩個群體，利用 ADInstruments PowerLab 儀器系統之 PPG 感測模組採集實驗訊號，分析兩個群體間之差異，並監測透析瘻管狀態，進而預測瘻管阻塞的機率。

1.4 論文大綱

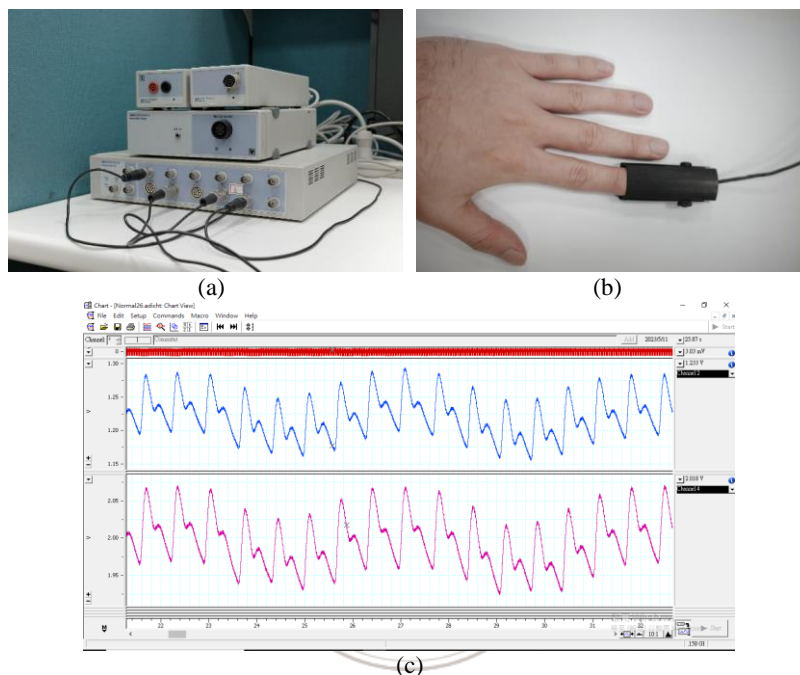
第二章會介紹我們使用的儀器、參與實驗的人員、實驗方法以及特徵參數的

介紹。第三章會說明訊號的前處理、特徵標記、訊號處理以及使用哪種分類器進行分類。第四章會說明分類器分類出來結果。第五章會總結分類出來的結果，以及未來可以改進的地方。



第二章 材料

2.1 研究儀器



圖一、PPG 訊號感測儀器：(a) PowerLab 系統、(b) 指夾式 PPG 感測器模組、
(c) LabChart 軟體操作畫面

在本研究中，我們使用 PowerLab 系統(如圖一(a)所示)進行 PPG 訊號的擷取，此系統是由 ADInstruments 公司所生產。PowerLab 可擷取和收集如 PPG、ECG 等生理訊號，同時也提供其他類比/數位生理訊號(例如：EMG 等)的輸入通道，以及支援其他類生理訊號之 A/D 轉換與訊號調變。本研究實驗使用了指夾式的 PPG 感測器模組(如圖一(b)所示)，此時 PPG 感測器的採樣率設為 1000Hz。另外，PowerLab 系統可搭配 LabChart 軟體，對 PPG 的原始訊號(如圖一(c)所示)進行即時顯示和觀察，並將 PPG 訊號儲存成.adicht 的檔案格式。而後續 PPG 訊號的分

析及處理，則是利用 Python 程式語言撰寫 PPG 訊號處理程式，來進行後續的訊號分析和應用。

2.2 受測者

本研究已通過國立成功大學醫學院附設醫院之醫學倫理審查委員會之醫學倫理審查，IRB 醫學倫理審查通過之核准文件編號為 A-ER-112-135，本研究所執行之實驗程序與實驗內容皆屬於非侵入式的行為，符合赫爾辛基宣言之精神。

在本研究中，將接受血液透析治療之病患依其瘻管狀態區分為「易阻塞病患」、「不易阻塞病患」兩組。另外，關於「易阻塞病患」及「不易阻塞病患」群組的實驗參與者，徵召來自國立成功大學醫學院附設醫院斗六分院的洗腎中心之病患。本研究實驗共有 21 位已接受瘻管手術的患者參與實驗，其中「易阻塞」的病患 4 位，「不易阻塞」的病患 17 位。

實驗參與者的選擇基於一系列納入或排除條件，詳列於表一中。選定的參與者需符合以下條件：年齡需大於等於 20 歲，而性別可以是男性或女性。此外，被選入實驗的參與者須在左手或右手處接受過自體動靜脈瘻管(arteriovenous fistula, AVF)及人工動靜脈瘻管(arteriovenous graft, AVG)，並且不得有心血管疾病的病史。另外，實驗參與者將依照瘻管介入手術的頻率，被區分為兩種類型：介入手術頻率高者，定義為三個月內接受過兩次以上瘻管介入手術，被歸類為「易阻塞病患」；介入手術頻率低者，被歸類為「不易阻塞病患」。

表 2-1 受試者納入條件


	易阻塞病患	不易阻塞病患
年齡	大於等於 20 歲	大於等於 20 歲
心血管疾病	無	無
是否安裝瘻管	是	是

介入頻率	三個月內兩次以上	三個月內小於兩次
------	----------	----------

2.3 實驗方法

在實驗開始前，會先向實驗參與者說明研究實驗流程，並向實驗參與者詢問瘻管位置。在本研究中，沒有安裝瘻管的手稱為健側手(Health Side: H)，有安裝瘻管的手稱為患側手(Affected Side: A)。而在本研究實驗所募集到的實驗參與者中，多數的患者之瘻管是安裝在左手，少數是安裝在右手。之後，將指夾式 PPG 感測器探頭夾住在實驗參與者的健側與患側雙手食指的指腹位置，並提醒實驗參與者放輕鬆。當手指頭被感測器夾住後，不要對感測器探頭作按壓動作。實驗時間一共進行 5 分鐘的 PPG 訊號擷取，如果實驗期間實驗參與者的瘻管有異常狀態，則標記此 PPG 訊號為異常訊號。

2.4 PPG 訊號與實驗特徵參數



圖二、PPG 訊號和其特徵點

在圖二中，我們可以觀察到一個心搏週期內的 PPG 訊號及其擁有的特徵點，包括：收縮壓峰值(Systolic Peak)、收縮壓峰腳(Systolic Foot)、以及心搏週期長度(Cardiac Cycle Interval)等。Systolic Peak 指的是 PPG 波形中收縮期的最大值，Systolic Foot 是 PPG 波形中收縮期的起始點，心搏週期指的是從本次心跳開始到

相鄰之下一次心跳開始之前，所經歷完整的過程，包含了一個收縮期與一個舒張期。而 Cardiac Cycle Interval 的衡量方式在許多的研究中，皆以 Systolic Peak to Peak Interval (SSI)來代替，指得是從本次心跳之 Systolic Peak 時間點到下一次心跳 Systolic Peak 時間點之間的間隔。Systolic Foot、Systolic Peak、SSI 等的量測與計算，有助於評估接受血液透析之病患的瘻管通路的良好狀態。

除了以上的參數之外，表二中顯示了在本研究中所提議的其他參數，例如：PPGA、PPGA-H/A、PPGA-A/H、PPG 上升時間、PPG 下降時間、SSI 等 PPG 參數。關於 PPGA 值之計算，其方法是透過 Systolic Peak 的 PPG 振幅值，減去 Systolic Foot 的 PPG 振幅值。而 PPGA-H/A 的值，是透過將健側手指獲得到的 PPGA 值，除以患側手指獲得到的 PPGA 值。反之，對於 PPGA-A/H 的值，則是將患側 PPGA 值除以健側 PPGA，所以 PPGA-A/H 和 PPGA-H/A 互為倒數關係。計算 PPG 上升時間時，其方法是透過當前 Systolic Peak 的時間點減去當前 Systolic Foot 的時間點，來獲得 PPG 上升時間數值。至於計算 PPG 下降時間，其方法是透過下一個 Systolic Foot 的時間點，減去當前 Systolic Peak 的時間點，以獲得 PPG 下降時間數值。

表二二、實驗特徵參數定義

特徵(參數)	定義
Systolic Foot	PPG 波形中收縮壓的起始點。
Systolic Peak	PPG 波形中收縮壓最大值。
Systolic Peak to Peak Interval (SSI)	本次 PPG 訊號波峰到下一個 PPG 訊號波峰的時間間隔。
PPGA	波谷到波峰的垂直振幅差。
PPGA-H/A、PPGA-A/H	PPGA-H/A：將健側 PPGA 值除以患側 PPGA。 PPGA-A/H：將患側 PPGA 值除以健側 PPGA。
PPG 上升時間	PPG 訊號從波谷到波峰時間。

PPG 下降時間	PPG 訊號從波峰到波谷時間。
AVG	整段資料的平均值。
STD	整段資料的標準差。
VAR	整段資料的變異度。

在本研究所使用的實驗特徵參數(如表二)中,還包括了 3 個統計特徵,例如:平均值(Average: AVG)、標準差(Standard Deviation: STD)、變異度(Variation: VAR)。有關於 AVG 和 STD 之計算公式如(公式一)和(公式二)所示,其中 N 是資料數值 X_i 的總數。

$$AVG = \frac{\sum_{i=1}^N X_i}{N} \quad (\text{公式一})$$

$$STD = \sqrt{\frac{\sum_{i=1}^N (X_i - AVG)^2}{N}} \quad (\text{公式二})$$

變異度(公式三)是醫學上常用於衡量一組數據(假設 $S=\{X_1, X_2, \dots, X_N\}$)分散程度的一種指標,其計算方式是將該組數據 S 之最大值減去同組數據之最小值,再除以同組全部數據之平均值,如(公式三)所示。

$$VAR = \frac{Max(S) - Min(S)}{AVG} \quad (\text{公式三})$$


其中 Max() 和 Min() 是求集合 S 中最大值和最小值的函數。


第三章 研究方法

在實驗中所擷取到的原始訊號，將進行訊號濾波處理工作，以濾除不必要的雜訊。之後的訊號處理，將會使用訊號特徵峰值檢測演算法標記出收縮壓腳(Systolic Foot)和收縮壓峰值點(Systolic Peak)，以及利用收縮壓腳值(Systolic Foot)或收縮壓峰值(Systolic Peak)的這兩個特徵點進行 Cardiac Cycle 的切割，以便找出表二所示之各個 PPG 特徵值。再利用切割之後的一個 Cardiac Cycle 與整段 PPG 訊號資料進行 Auto-/Cross-Correlation 運算，來計算不同的 PPG 訊號來源之間的相關性，並提取後續要進行統計推論和智慧辨識的相關性特徵。

3.1 訊號前處理

透過 PowerLab 系統之 PPG 感測模組所擷取到的左/右雙手 PPG 原始訊號(圖三(a))，這些原始訊號含有大量的雜訊，例如：呼吸、環境光源、手部運動造成的基線飄移、運動偽影等。為了要去除這些雜訊，我們使用了 Butterworth 帶通濾波器進行雜訊處理[12]。這些原始訊號將會經過 4 階 Butterworth 帶通濾波器的訊號處理，該濾波器之導通頻帶設定為 0.5HZ 到 7HZ 之間，這有助於去除呼吸、環境光源、手部運動造成的基線飄移、運動偽影等，使得 PPG 訊號更加可靠且有利於後續的瘻管阻塞狀態之分析和辨識，如圖三(b)所示。





(b)

圖三、PPG 訊號—(a)原始訊號，(b)去除雜訊後的訊號

3.2 訊號處理

3.2.1 峰值特徵標記

經過 Butterworth 濾波器處理後，原始訊號已經被轉換為濾波過後的 PPG 訊號。在接下來步驟中，我們將對經過濾波的訊號進行峰值標記，以便於後續進行 PPG 訊號週期分割與訊號特徵計算。在 PPG 訊號峰值檢測方法中，我們使用了 Python 程式語言的 Scipy 函式庫中的 find-peaks 函式，來進行濾波過後 PPG 訊號中的峰值偵測，這些峰值標記結果如圖三(b)中之波峰和波谷的標記點所示。

3.2.2 Cardiac Cycle Segmentation

透過 PPG 訊號峰值檢測方法處理後，我們可將收縮期峰值點(Systolic Peak)與收縮期谷值點(Systolic Foot)標記出來，再透過這兩種標記方式，來分割出各別獨立的心搏週期(Cardiac Cycle)。在本研究中，我們採用 Systolic Peak 作為心搏週期的分割點，以獲得心搏週期間隔的數值。當偵測到第 i 個 Systolic Peak 時，第 i 個 Systolic Peak 與第 $i+1$ 個 Systolic Peak 之間的區間資料，可視為是第 i 個 Cardiac Cycle，利用此方法可以完成各個單獨的心搏週期之分割(Cardiac Cycle Segmentation)。

基於以上心搏週期之分割方法，在本研究的後續特徵資料計算過程中，皆以 Systolic Peak 作為心搏週期的分割點，從而產生與 PPG 心搏週期訊號相關的各種癢管阻塞狀態之特徵資訊。

3.2.3 Auto-/Cross-Correlation 運算

自相關/互相關運算(Auto-/Cross-Correlation: CC)是一種於訊號處理中常用的數學運算方法(公式四)，透過滑動點積計算的方式來衡量兩個數值序列間之相似性或關聯性的一種方法。假設一組經濾波處理後的 PPG 訊號數列為 Q_i (其中 $1 \leq i \leq M$, M 是一個整數)，則將 Q 設為執行自相關/互相關運算的左手/右手 PPG 訊號資料(Data)集合(如圖三(b))。利用前述的 Cardiac Cycle 分割方法，將 Data 集合中的資料進行 Cardiac Cycle 分割，並從分割後的 Data 集合中，隨機找出一個完整的 Cardiac Cycle 集合，將它當作是執行自相關/互相關運算所需要的滑動視窗訊號之左手/右手 PPG 訊號資料數列 P_j (其中 $1 \leq j \leq N$, N 是一個整數)，也就是當作滑動視窗的 Pattern 集合，則可實行自相關/互相關計算的公式如下所示。

$$CCr(t) = \frac{\sum_{i=1}^N (P_i - \bar{P})(Q_{i+t} - \bar{Q}_t)}{\sqrt{\sum_{i=1}^N (P_i - \bar{P})^2 \sum_{i=1}^N (Q_{i+t} - \bar{Q}_t)^2}} \quad (\text{公式四})$$

其中 Data 的長度為 M ，Pattern 的長度為 N ，且 M 會大於或等於 N 。另外， t 為整數指標變數，且 $1 \leq t \leq (M-N+1)$ ， \bar{P} 是集合 P 集合的平均值， \bar{Q}_t 則是 Q 集合的部分集合(例如： $(Q_{(t+1)}, \dots, Q_{(t+n)})$)之平均值，對於每個 $CCr(t)$ 的計算值，其正規化後範圍為 -1 到 1 之間。

當進行完自相關/互相關運算後，相關數列 $CCr(t)$ (其中 $1 \leq t \leq (M-N+1)$) 儲存了在 Q 數列上滑動 P 數列作自相關/互相關計算的結果(公式四)，則這段相關數列 $CCr(t)$ 的資料長度為 $M-N+1$ 。

3.2.4 Auto-/Cross-Correlation 資料模型

Auto-/Cross-Correlation 資料模型之建立，可分成兩個階段。第一階段是使用 Auto-/Cross-Correlation 運算，建立健側手指與患側手指的 PPG 訊號之二種自相關和二種互相關等運算組合，分別以 HH、AA 代表自相關運算組合，以及以 HA、AH 代表互相關運算組合。第二階段則是根據 HH、AA、HA、AH 等自相關/互相關

關係數數列所形成之係數曲線，計算其曲線下的面積，提供後續對瘻管通路狀態之統計推論和智慧辨識。

透過上述這兩個階段所建立的 Auto-/Cross-Correlation 資料模型，可以用來揭露和評估血液透析用瘻管通路狀態的良好程度。主要理論是，基於一般狀況下病患所安裝的瘻管是橋接於患者手部(亦即指的是患側手部)的動脈與靜脈之間，因此每當 PPG 脈衝通過動脈與瘻管的接點時，瘻管的狀態就可以分成下列兩種：

- 如果**瘻管不易阻塞**的話，PPG 脈衝通過該點時，脈衝壓會被分散，這導致了我們於患側手部位的食指位置所測得的 PPG 訊號，將會迥異於健側手部位的食指位置所測得的 PPG 訊號。
- 如果**瘻管易阻塞**的話，此時每個 PPG 脈衝壓在動脈與瘻管接點位置就不會過度被分散，這就造成了健側與患側部位的食指上所測得之 PPG 訊號會有很高的相似性。

以上兩種瘻管狀態，將可被定義為後續進行統計推論的因變量，以及作智慧辨識時的目標現象。

以上兩個階段的詳細工作流程，描述如下：

第一階段：將左/右雙手經訊號處理濾波後之 PPG 訊號，利用前述對 Cardiac Cycle 分割的方法，分割出相對於實驗參與者健側與患側的 PPG 訊號之滑動視窗訊號數列之 H_Pattern 與 A_Pattern。然後，將分割完成後的 PPG Pattern 與 PPG Data 進行匹配組合運算，使其可以產生 H_Data-H_Pattern (HH)、A_Data-A_Pattern (AA)、H_Data-A_Pattern (HA)與 A_Data-H_Pattern (AH)等四種自相關/互相關係數運算組合。自相關/互相關係數運算之執行步驟，敘述如下：


步驟一：利用 Cardiac Cycle 分割出 H-Pattern 和 A-Pattern。

步驟二：利用分割出來的 H-Pattern 與 A-Pattern 和 H-Data 與 A-Data，進行配對組合之自相關/互相關係數運算。

步驟三：經自相關/互相關係數運算後，產生 HH、AA、HA、AH 等四種組合，

再分別計算出 HH、AA、HA、AH 等四種組合各別的自相關/互相關係數數列之平均數(AVG)、標準差(STD)、變異度(VAR)等數據。

第二階段：我們將計算出的 HH、AA、HA、AH 等四種自相關/互相關係數數列，對這些數列的曲線進行曲線下面積之計算(如圖四所示)。根據曲線數值，我們可以進行以下判斷；當曲線的數值大於 0 時，計算所得之曲線下面積稱為正區域面積(Poitive area: P-area)，該區域在圖九中以綠色部分表示。而當曲線數值小於 0 時，則稱為負區域面積(Negative area: N-area)，該區域以紅色部分表示。



圖四、自相關/互相關係數數列曲線下之面積

3.3 參數之統計分析

在本研究中，進行統計分析的自變量之參數種類，可以分為三種類別。首先，是由自相關/互相關運算經計算而得的自相關/互相關係數數列(例如：HH、AA、HA、AH 等四種組合)的平均數(AVG)、標準差(STD)、變異度(VAR)，這些參數組合形成第一類參數集合。其次，透過峰值檢測方法，識別出患側手/健側手之 PPG 訊號的波峰與波谷，進而計算得到 PPGA、PPGA-H/A、PPGA-A/H、PPG 上升時間、PPG 下降時間、以及 SSI 等，這些參數構成了第二類參數集合。最後，透過自相關/互相關運算所獲得的相關係數數列之曲線下面積，亦即 P-area 和 N-area，形成了第三類參數集合。

而統計分析的因變量，則設定為接受血液透析治療之瘻管通路，是「易阻塞病患」或是「不易阻塞病患」等兩個群體。為了評估以上三類自變量參數在統計

分析上，針對因變量參數的差異顯著性，我們利用獨立樣本 T 檢定來進行分析和評估[13]。在進行 T 檢定時，我們需要設置虛無假設 H_0 和對立假設 H_1 。虛無假設是對母體參數提出一個主張，假設此主張為真實的。對立假設是相對於虛無假設所提出之相對立的另一個假設或主張，必須有足夠的證據，才能說明此主張為真，表三至表五則呈現了各類別自變量之參數的 P-value 值。

表三三、第一類參數 T-test 之 P-value 值

Parameter	P-value
HH-AVG	0.106 [☆]
HH-STD	0.96
HH-VAR	0.77
AA-AVG	0.99
AA-STD	0.62
AA-VAR	0.76
HA-AVG	0.82
HA-STD	0.37
HA-VAR	0.30 [★]
AH-AVG	0.87
AH-STD	0.80
AH-VAR	0.83

表四四、第二類參數 T-Test 之 P-value 值

Parameter	P-value(健側手)	P-value(患側手)
PPGA	0.24 [★]	0.77
PPGA-H/A ^(a) , PPGA-A/H ^(b)	<u>0.06</u> <u>.0.2</u>	0.20 ^(b) [★]

PPG 上升時間-AVG	0.46	0.65
PPG 上升時間-STD	0.25 [★]	0.46
PPG 上升時間-VAR	0.25 [★]	0.409
PPG 下降時間-AVG	0.85	0.05 [*]
PPG 下降時間-STD	0.2 [★]	0.29 [★]
PPG 下降時間-VAR	0.26 [★]	0.29 [★]
SSI-AVG	0.06 [☆]	0.06 [☆]
SSI-STD	0.06 [☆]	0.06 [☆]
SSI-VAR	0.15 [★]	0.15 [★]

表 五五、第三類參數 T-Test 之 P-value 值

Parameter	P-value
HH-P-area	0.06 [☆]
HH-N-area	0.828
AA-P-area	0.361
AA-N-area	0.45
HA-P-area	0.087 [☆]
HA-N-area	0.292 [★]
AH-P-area	0.346 [★]
AH-N-area	0.419

3.4 智慧辨識

從表三至表五中 P-value 所顯示的結果，可以看出幾乎所有的自變量參數，都無法展示出對於兩種癭管狀態的因變量，是具有顯著性的差異。因此，我們嘗

試使用表三至表五中的自變量參數，依其 P-value 大小之值選擇兩個自變量特徵集合，再利用 K-Nearest Neighbors 與 Support Vector Machine 等監督式學習演算法，進行兩種瘻管狀態的智慧辨識。其中，第一個自變量特徵集合(named as Feat.Set-1)為表三至表五中 P-value 小於 0.1 的所有自變量參數所組成之集合，第二個自變量特徵集合(named as Feat.Set-2)為表三至表五中 P-value 小於 0.35 的所有自變量參數所組成之集合。這兩個特徵集合列出如下：

Feat.Set-1={HH-AVG, PPG 下降時間-AVG-A, SSI-AVG-H, SSI-AVG-A, SSI-STD-H, SSI-STD-A, HH-P-area, HA-P-area},

Feat.Set-2={HH-AVG, HA-VAR, PPGA-A/H, PPG 上升時間-STD-H, PPG 上升時間-VAR-H, PPG 下降時間-AVG-A, PPG 下降時間-STD-H, PPG 下降時間-STD-A, PPG 下降時間-VAR-H, PPG 下降時間-VAR-A, SSI-AVG-H, SSI-AVG-A, SSI-STD-H, SSI-STD-A, SSI-VAR-H, SSI-VAR-A, HH-P-area, HA-P-area, HA-N-area, AH-P-area}.

3.4.1 kNN

K 個最近鄰演算法(k-Nearest Neighbors, kNN)[14, 15]是一種監督式學習演算法，可應用於分類和回歸問題。kNN 通過比較待分類樣本和其他樣本之間的特徵距離，來進行預測。在本研究中，我們將使用曼哈頓距離(Manhattan distance，如公式五所示)[16]，來計算不同樣本之間的距離。這種距離度量方式可以表示為 $d(x, y)$ ，其中 x_i 屬於一個訓練數據集合，而 y_i 則為一個查詢點。透過公式五，找出 x_i 與 y_i 兩點之間的距離。

$$d(x, y) = \sum_{i=1}^n |x_i - y_i| \quad \text{公式五}$$

在分類問題上，kNN 根據最相鄰的 K 個鄰居中所屬的最大多數標籤之類別，來確定新的查詢點所屬的標籤之類別；在回歸問題中，kNN 使用鄰居的數值平均值來預測新的查詢點的標籤值。

kNN 的主要優點在於演算步驟簡單易懂，易於實現與解釋，它不需要複雜數

學模型。然而，kNN 也有缺點，對於大型數據集，kNN 的計算成本相對較高。因為每次預測都需要計算待分類樣本與所有訓練樣本之間的距離，這增加了計算的負擔。此外，選擇不適合的 K 值可能導致預測結果的有偏差，因此選擇適合的 K 值對於獲得較高準確率的結果很重要。

3.4.2 SVM

支持向量機(Support Vector Machine, SVM)[17, 18]是一種監督式學習演算法，可用於分類和回歸問題中，並在智慧辨識領域具有廣泛的應用。SVM 的主要思想是在一個高維度的空間中，找到一條最佳的決策邊界(Decision Boundary)，如公式六所示。

$$y(x) = \omega^T x + b = 0 \quad \text{公式六}$$

其中， $y(x)$ 表示分類模型的輸出函數，對於輸入的特徵向量 x ，模型預測的輸出值，針對 2 個類別的分類函數 $y(x)$ 會有+1 與-1 的兩個輸出數值，這用於表示數據的類別。 ω^T 代表權重向量，用於表示分類超平面的方向，使其方便與特徵向量 x 進行內積運算。 x 代表是我們輸入到分類模型的特徵， b 為一個常數，調整 b 的數值可以使回歸線在空間中作平移動作。

在分類模型中的決策邊界，可以將不同類別的數據有效地分隔開來。從決策邊界(Decision Boundary)上/下移動 1 個單位距離，以延伸出兩條邊界，如公式七所示。在這兩條邊界之間，可視為是一個緩衝區，當緩衝區越大時，分類結果的可信度就越高。

$$\begin{cases} y(x) = \omega^T x + b = 1 \\ y(x) = \omega^T x + b = -1 \end{cases} \quad \text{公式七}$$

SVM 可使用不同的 Kernel Function，例如：線性核函數(Linear Kernel)、多項式核函數(Polynomial Kernel)和高斯核函數(Gaussian Kernel)，這些核函數可將低維度的數據轉映射至高維度空間，從而獲得更高的分類準確率。另外，當處理大型數據集並使用非線性核函數時，SVM 的計算成本可能會相對提高，這也是需要考慮的一環。

第四章 結果分析

在本研究中，自變量參數經過獨立樣本 T 檢定後，將會以統計分析結果所產生的兩個自變量特徵集合(Feat.Set-1 和 Feat.Set-2)，進行 kNN 與 SVM 兩種監督式學習演算法的訓練和智慧辨識。

本研究實驗共有 21 位安裝慶管的患者參與實驗，其中「易阻塞」的病患 4 位，「不易阻塞」的病患 17 位。

為了增加訓練模型的可靠性，我們採用了 K-Fold 交叉驗證策略，在 K-Fold 方法中會將資料集合切割分成 K 個子集合。本次實驗 K-Fold 的 K 值設為 5，也就是將資料集合切割成五等份。意味著辨識模型訓練要進行五次，每次會從這五份隨機挑選其中四份當作是訓練資料集，另外一份當作是驗證集。最終，再取每次辨識結果的平均值，作為模型評估的效能指標值。為了評估模型效能，我們可以透過分類完成後產生的混淆矩陣(表六)進行準確率(Accuracy)、靈敏度(Sensitivity)、特異度(Specificity)、精確度(Precision)與 F1-score(公式八至公式十二)等，進行辨識效果的評估。

表六六、混淆矩陣示意圖

		實際值	
		類別一	類別二
預測值	類別一	TP	FP
	類別二	FN	TN

$$Accuracy = \frac{TP+TN}{TP+FP+FN+TN} \quad \text{公式八}$$

$$Sensitivity = \frac{TP}{TP+FN} \quad \text{公式九}$$

$$Specificity = \frac{TN}{TN+FP} \quad \text{公式十}$$


$$Precision = \frac{TP}{TP+FP} \quad \text{公式十一}$$

$$F1 - score = \frac{2 * (Recall * Precision)}{Recall + Precision}$$

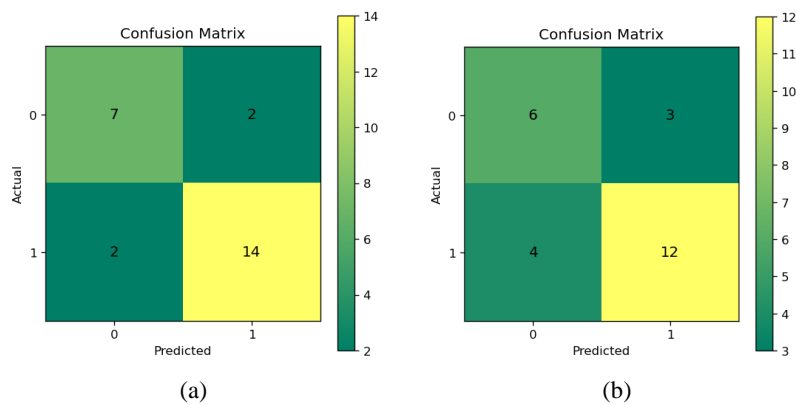
公式十二

4.1 kNN 分析

當使用 Feat.Set-1 和 Feat.Set-2 等兩個特徵集進行 kNN 模型訓練時，我們發現在不同的 k 值下，獲得了不同的結果，如圖五所示。在使用 Feat.Set-1 特徵集進行 kNN 模型訓練時，當我們將 k 設置為 1，我們可得到的最高辨識準確率為 0.84。當我們使用 Feat.Set-2 特徵集進行訓練，且將 k 設置為 3 時，我們取得的最佳辨識準確率為 0.72。



圖五、不同 k 值下 kNN 模型的辨識準確度—(a)使用 Feat.Set-1 特徵集、(b)使用 Feat.Set-2 特徵集



圖六、基於 Feat.Set-1 和 Feat.Set-2 特徵集進行辨識之 kNN 混淆矩陣，(a)使用 Feat.Set-1、(b)使用 Feat.Set-2

針對 Feat.Set-1 特徵集進行 kNN 模型訓練的結果，其所對應的混淆矩陣，如圖六所示。其中，Label0 代表是易阻塞病患，Label1 為不易阻塞病患，對 Feat.Set-1 特徵集在 k 設置為 1 時，取得了最高的辨識準確率(0.84)和 F1-score (0.77)。另外，針對使用 Feat.Set-2 特徵集，且在 k 設置為 3 時，可取得最高的辨識準確率(0.72)和 F1-score (0.63)。

除了混淆矩陣外，表七顯示了使用兩個不同特徵集所計算出的效能指標，例如：Accuracy、Sensitivity、Specificity、Precision 和 F1-score。這些指標可提供分類器的性能進行評估，以便了解 kNN 模型之效能表現。

表七、針對 Feat.Set-1 和 Feat.Set-2 特徵集之 kNN 效能指標

	Accuracy	Sensitivity	Specificity	Precision	F1-score
Feat.Set-1	0.84	0.77	0.87	0.77	0.77
Feat.Set-2	0.72	0.66	0.75	0.60	0.63

4.2 SVM 分析

當使用 Feat.Set-1 特徵集進行 SVM 模型訓練時，使用不同 Kernel Function 下的準確度如表八所示，使用 Linear 的 Kernel Function 其辨識準確率為 0.88，圖九(a)為 SVM 的混淆矩陣，其中 Label0 為易阻塞病患，Label1 為不易阻塞病患。針對使用 Feat.Set-2 特徵集進行 SVM 模型訓練時，使用不同 Kernel Function 下的準確率如表九所示，使用 Polynomial 的 Kernel Function 其準確率為 0.76，圖九(b)為其混淆矩陣。另外，表十則展示了 SVM 在使用 Feat.Set-1 和 Feat.Set-2 特徵集時的各項效能指標。值得注意的是，在使用線性核函數對 Feat.Set-1 所進行的辨識之下，獲得了最好的辨識準確率(0.88)和 F1-score (0.82)。

格式化: 字型色彩: 紅色

格式化: 左右對齊, 沒有段落遺留字串控制

格式化: 字型: 非粗體, 字型色彩: 紅色

格式化: 字型: 12 點, 非粗體

已註解 [U1]:

格式化: 字型: 12 點

格式化: 字型: 粗體, 隱藏


格式化: 左右對齊, 縮排: 第一行: 0 公分, 沒有段落遺留字串控制

表八 使用 Feat.Set-1 於 SVM 在不同核函數下之準確率

<u>Linear</u>	<u>Polynomial</u>	<u>RBF</u>
<u>0.88</u>	<u>0.80</u>	<u>0.64</u>

表九 使用 Feat.Set-2 於 SVM 在不同核函數下之準確率

<u>Linear</u>	<u>Polynomial</u>	<u>RBF</u>
<u>0.72</u>	<u>0.76</u>	<u>0.64</u>



圖九、基於(a) Feat.Set-1 特徵集、(b) Feat.Set-2 特徵集，進行辨識之 SVM 混淆矩陣

表九、SVM 效能指標

表十、SVM 效能指標

	Accuracy	Sensitivity	Specificity	Precision	F1-score
Feat.Set-1	0.88	0.77	0.93	0.87	0.82
Feat.Set-2	0.76	0.66	0.81	0.66	0.66

4.3 討論



第五章 結論

我們運用由 ADIstruments 公司生產的 PowerLab 設備，從不同的實驗參與者中，收集他們左/右手的 PPG 訊號，並分為不易阻塞與易阻塞等兩類型病患。我們的研究目標，是通過處理和分析這類型病患的 PPG 訊號，對實驗參與者作準確的分類。

在收集到的訊號上，我們進行了訊號前處理並計算了三類參數，第一類參數則是自/互相關數列的參數；第二類為 PPG 型態學上的參數；第三類則是自相關/互相關數列頻譜曲線下的面積，使用這三類參數透過 kNN 與 SVM 進行智慧分類。分類結果是使用 Feat.Set-1 特徵集的 SVM，獲得了最佳的準確度 0.88。

儘管我們透過 SVM 達到 0.88 的最佳準確率，成功區分了不易阻塞和易阻塞的病患，但我們認為目前成果仍存在進一步改進的空間。未來，我們將專注於預測癢管阻塞的時間，特別是針對不易阻塞和易阻塞的病患區別。



參考文獻

- [1] Y. C. Lin, M.-S. Wu, M.-Y. Wu, Z. cai-mei, and C.-C. Hsu, "Summary Report of the 2019 Annual Report on Kidney Disease in Taiwan," pp. 3-14, 02 2021, doi: 10.6221/AN.202103_35(1).0002.
- [2] P. Ravani *et al.*, "Associations between hemodialysis access type and clinical outcomes: a systematic review," (in eng), *J Am Soc Nephrol*, vol. 24, no. 3, pp. 465-73, Feb 2013, doi: 10.1681/asn.2012070643.
- [3] P. Ravani *et al.*, "Temporal risk profile for infectious and noninfectious complications of hemodialysis access," (in eng), *J Am Soc Nephrol*, vol. 24, no. 10, pp. 1668-77, Oct 2013, doi: 10.1681/asn.2012121234.
- [4] E. Anvari and T. J. Vachharajani, "The Hemodialysis Access Surveillance Controversy Continues," (in eng), *Kidney Int Rep*, vol. 5, no. 11, pp. 1848-1850, Nov 2020, doi: 10.1016/j.ekir.2020.09.037.
- [5] P.-Y. Chiang *et al.*, "Machine Learning Classification for Assessing the Degree of Stenosis and Blood Flow Volume at Arteriovenous Fistulas of Hemodialysis Patients Using a New Photoplethysmography Sensor Device," *Sensors*, vol. 19, no. 15, p. 3422, 2019. [Online]. Available: <https://www.mdpi.com/1424-8220/19/15/3422>.
- [6] C. E. Lok *et al.*, "KDOQI Clinical Practice Guideline for Vascular Access: 2019 Update," (in eng), *Am J Kidney Dis*, vol. 75, no. 4 Suppl 2, pp. S1-s164, Apr 2020, doi: 10.1053/j.ajkd.2019.12.001.
- [7] P. C.-P. Chao and P.-Y. Chiang, "Theoretical development with proper approximation and the corresponding clinical experiments for PPG sensor monitoring blood flow volume of hemodialysis patients with arteriovenous fistula," *2017 International Conference on Applied System Innovation (ICASI)*, pp. 311-314, 2017.
- [8] P.-Y. Chiang, P. Chao, D.-C. Tarng, and C.-Y. Yang, "A Novel Wireless Photoplethysmography Blood Flow Volume Sensor for Assessing Arteriovenous Fistula of Hemodialysis Patients," *IEEE Transactions on Industrial Electronics*, vol. PP, pp. 1-1, 05/08 2017, doi: 10.1109/TIE.2017.2701780.
- [9] J. X. Wu, C. H. Lin, M. J. Wu, C. M. Li, B. Y. Lim, and Y. C. Du, "Bilateral photoplethysmography analysis for arteriovenous fistula dysfunction screening with fractional-order feature and cooperative game-based embedded detector," (in eng), *Healthc Technol Lett*, vol. 2, no. 3, pp. 64-9, Jun 2015, doi: 10.1049/htl.2014.0090.
- [10] Y.-C. Du and A. Stephanus, "A Novel Classification Technique of Arteriovenous

- Fistula Stenosis Evaluation Using Bilateral PPG Analysis," *Micromachines*, vol. 7, no. 9, p. 147, 2016. [Online]. Available: <https://www.mdpi.com/2072-666X/7/9/147>.
- [11] Y. C. Du and A. Stephanus, "Levenberg-Marquardt Neural Network Algorithm for Degree of Arteriovenous Fistula Stenosis Classification Using a Dual Optical Photoplethysmography Sensor," (in eng), *Sensors (Basel)*, vol. 18, no. 7, Jul 17 2018, doi: 10.3390/s18072322.
- [12] Y. Liang, M. Elgendi, Z. Chen, and R. Ward, "An optimal filter for short photoplethysmogram signals," (in eng), *Sci Data*, vol. 5, p. 180076, May 1 2018, doi: 10.1038/sdata.2018.76.
- [13] T. Kim, "T test as a parametric statistic," *Korean Journal of Anesthesiology*, vol. 68, p. 540, 11 2015, doi: 10.4097/kjae.2015.68.6.540.
- [14] Z. Zhang, "Introduction to machine learning: k-nearest neighbors," (in eng), *Ann Transl Med*, vol. 4, no. 11, p. 218, Jun 2016, doi: 10.21037/atm.2016.03.37.
- [15] T. Cover and P. Hart, "Nearest neighbor pattern classification," *IEEE Transactions on Information Theory*, vol. 13, no. 1, pp. 21-27, 1967, doi: 10.1109/TIT.1967.1053964.
- [16] R. Short and K. Fukunaga, "The optimal distance measure for nearest neighbor classification," *IEEE Transactions on Information Theory*, vol. 27, no. 5, pp. 622-627, 1981, doi: 10.1109/TIT.1981.1056403.
- [17] B. Schölkopf and A. J. Smola, *Smola, A.: Learning with Kernels - Support Vector Machines, Regularization, Optimization and Beyond*. MIT Press, Cambridge, MA. 2001.
- [18] C. Cortes and V. Vapnik, "Support-vector networks," *Machine Learning*, vol. 20, no. 3, pp. 273-297, 1995/09/01 1995, doi: 10.1007/BF00994018.